



Préliminaires : Admission d'étudiants

On considère un comité d'admission d'un programme d'enseignement supérieur qui doit statuer sur l'admission d'étudiants sur la base de leurs évaluations dans quatre cours : mathématiques (M), physique (P), littérature (L) et histoire (H). Les évaluations de tous les cours sont comprises dans l'intervalle $[0, 20]$. Pour être admis ($\mathcal{A}$) au programme, le comité considère qu'un étudiant doit obtenir au moins 12/20 dans une "majorité" de cours ; sinon, il est refusé ($\mathcal{R}$). Du point de vue du comité, tous les cours (critères) n'ont pas la même importance. Pour définir la majorité requise de cours, le comité attribue à chaque cours un poids $w_j \geq 0$, de sorte que leur somme soit égale à 1 ; un sous-ensemble de cours $\mathcal{C} \subseteq \{M, P, L, H\}$ est considéré comme une majorité si $\sum_{j \in \mathcal{C}} w_j \geq \lambda$, où $\lambda \in [0, 1]$ est un niveau de majorité requis.

- i. On considère les étudiants suivants, avec $w = (0.25, 0.15, 0.2, 0.4)$ et $\lambda = 0.66$. Quels étudiants sont admis ? Bob pense que sa copie en Physique a été sous-évaluée et demande une re-correction. Peut-il améliorer sa situation ? Expliquez pourquoi.

	M	P	L	H
Alice	11	12	13	12
Bob	13	12	15	10
Charlie	11	13	11	13
David	12	12	16	12

- ii. Définir les poids w_j et λ pour qu'un étudiant soit admis quand il obtient une note supérieure à 12 dans au moins 3 cours sur 4.
- iii. Avec 3 cours, comment interpréteriez-vous les valeurs suivantes pour w_j et λ . Que pouvez-vous conclure ?

- $w = (0.49, 0.49, 0.02)$ avec $\lambda = 0.5$? $w = (\frac{1}{3}, \frac{1}{3}, \frac{1}{3})$ avec $\lambda = 0.5$?

- iv. Cette procédure d'admission est un cas particulier d'une procédure générale, appelée MR-Sort, visant à accepter/rejeter des objets x définis par un vecteur de performances $x = (x_1, \dots, x_n)$ qui peut s'exprimer comme suit :

$$x \in \mathcal{A} \Leftrightarrow \sum_{i \in \mathcal{N}: x_i \geq b_i} w_i \geq \lambda$$

où $\mathcal{N} = \{1, \dots, n\}$ représente l'ensemble des critères, $w_i \geq 0$ le poids du critère i , $\lambda \geq 0$ un seuil de majorité, et $b = (b_1, b_2, \dots, b_n)$ représente la frontière ($b = (12, 12, 12, 12)$ dans notre exemple d'admission). Nous cherchons à déterminer les paramètres de la méthode MR-Sort à partir d'un jeu

de données. Plus précisément, nous connaissons un ensemble d'objets acceptés A^* et un ensemble d'objets rejetés R^* , chacun décrit par leur vecteur d'évaluation $(x_1, \dots, x_n)$.

Dans cette question, nous supposons que la limite $b = (b_1, b_2, \dots, b_n)$ entre les catégories $\mathcal{A}$ et $\mathcal{R}$ est connue. Formulez un programme linéaire qui détermine les valeurs de w_j et λ correspondant au mieux à l'ensemble de données $A^* \cup R^*$ (définissez les variables de décision, les contraintes et la fonction objectif).

- v. Dans ce qui suit, le profil limite définissant la frontière entre les deux classes $b = (b_1, b_2, \dots, b_n)$ est inconnue et reste à déterminer (comme les paramètres w_i et λ). Nous définissons des variables booléennes $\delta_i(x) \in \{0, 1\}$, pour chaque critère i et chaque étudiant x , telles que $\delta_i(x) = 1 \Leftrightarrow x_i \geq b_i$ et $\delta_i(x) = 0 \Leftrightarrow x_i < b_i$. Définir des contraintes sur $\delta_i(x), x_i, b_i$ qui garantissent la définition correcte de $\delta_i(x)$.

- vi. À partir des variables booléennes $\delta_i(x)$, on définit des variables continues $w_i(x)$, pour chaque critère i et chaque étudiant x , telles que :

$$w_i(x) = \begin{cases} w_i & , \text{ if } x_i \geq b_i \\ 0 & , \text{ sinon.} \end{cases}$$

où w_i représente le poids du critère i . Démontrez que si les contraintes définies ci-dessous sont vérifiées, alors les variables $\delta_i(x)$ et $w_i(x)$ se comportent comme prévu. Que représente l'expression $\sum_i w_i(x)$? Déduisez une condition sur les variables $w_i(x)$ qui garantit l'admission de l'étudiant x .

$$\begin{cases} w_i \geq w_i(x) \geq 0 \\ \delta_i(x) \geq w_i(x) \geq \delta_i(x) + w_i - 1 \end{cases}$$

- vii. Ecrivez le programme mathématique qui permet d'apprendre simultanément le profil limite définissant la frontière entre les deux classes $b = (b_1, b_2, \dots, b_n)$, et les coalitions de critères gagnants (w_j et λ) à partir d'un ensemble d'apprentissage.
- viii. Utilisez le solveur de programmation mathématique GUROBI pour résoudre programme mathématique défini au vii.
- viii. On se place maintenant dans le cas plus général où il y a p catégories $\mathcal{C}^1, \dots, \mathcal{C}^h, \dots, \mathcal{C}^p$, ($p \geq 2$), chacune définie par deux frontières ; ainsi la catégorie $\mathcal{C}^h$ est définie par sa frontière inférieure $b^{h-1} = (b_1^{h-1}, \dots, b_n^{h-1})$ et sa frontière supérieure $b^h = (b_1^h, \dots, b_n^h)$. Généralisez la formulation précédente au cas où il y a plus de deux catégories .

Organisation générale du projet

Le projet doit être réalisé en groupe de trois étudiants. Trois séances de cours seront consacrées à ce projet (02/10/2026, 16/10/2026 et 26/10/2026). Deux rendu intermédiaires sont attendu (le 06/10/2026, 23:59 et le 20/10/2026, 23:59). La présence de tous aux trois séances projet est obligatoire et sera contrôlée. La participation active à ces séances projet fait partie intégrante de l'évaluation du projet. Les soutenances sont planifiées le 06/11/2026. Lors de la soutenance, la présence et la participation active de chacun des membre du trinôme est requise.

Travail demandé pour le jalon 1

A l'issue de la première séance projet (02/10/2025), un premier rendu intermédiaire est demandé, et devra être déposé dans l'espace Edunao du cours (deadline 06/10/2026, 23h59). Pour le rendu intermédiaire 1, l'attendu est un programme qui en entrée prend un jeu de données, soit :

- le nombre de critères n ,
- le nombre de catégories p ,
- un learning set $\mathcal{L}$, c'est-à-dire un ensemble d'objets x définis par un vecteur de performances $x = (x_1, \dots, x_n)$ et une classe associée.

et calcule (par résolution avec GUROBI du programme mathématique défini au vii.) les paramètres du modèle MR-Sort qui restituent au mieux le learning set.

Pour valider votre

- Prendre en main le solveur GUROBI avec le notebook TP_0
- Implémenter votre modèle et vérifier son bon fonctionnement avec le jeu de données `Datataset0`.
- Tester la performance de votre solution en procédant comme suit :
 - Générer aléatoirement un modèle MR-Sort ground truth $\mathcal{M}_l$ (poids, λ et limites des catégories)
 - Générer aléatoirement des objets x définis par un vecteur de performances $x = (x_1, \dots, x_n)$ et les classer selon le modèle MR-Sort ground truth $\mathcal{M}_l$. Ceci constitue votre learning set $\mathcal{L}$.
 - En utilisant votre programme d'apprentissage, apprendre le modèle MR-Sort $\mathcal{M}^*$ qui restitue au mieux le learning set $\mathcal{L}$.
 - Générer aléatoirement un ensemble d'objets test $\mathcal{T}$; les classer avec $\mathcal{M}_l$ et $\mathcal{M}^*$. Calculer la qualité du modèle inféré, i.e. la proportion d'objets affectés à la même classe par $\mathcal{M}_l$ et $\mathcal{M}^*$.
- répéter ce test sur une vingtaine pour obtenir une valeur moyenne de la qualité de la solution obtenue.

Votre Jalon 1 doit être déposé sur Edunao au plus tard le 06/10/2026, 23:59.

Travail demandé pour le jalon 2

Un supermarché a une base de données des “tickets de caisse” et voudrait en tirer partie pour revoir la liste des produits mis en rayon dans le but de satisfaire les clients et maximiser le chiffre d’affaire. Dans la base de données, chaque produit est décrit par un vecteur de n features décrivant les qualités du produit. Ainsi le produit x est décrit par un vecteur $(x_1, \dots, x_i, \dots, x_n)$ où x_i représente la qualité du produit x sur la feature i (on supposera par la suite que le produit x est d’autant meilleur que x_i est élevé).

A partir de la base de données, produits ont été catégorisés en 3 classes (achats très fréquents, achats fréquents, peu ou pas d’achats) sur la base des achats des deux mois précédent considérés comme représentatifs. Cette classification a été établie par les responsables du supermarché sur la base du nombre d’achats sur la période et de leur connaissance métier.


On cherche à apprendre un modèle de classification de type MR-Sort à partir des données de ce problème. Ce problème d’apprentissage (inv-MR-Sort) est connu comme étant NP-Difficile. La bibliothèque <https://pypi.org/project/lincs/> propose une implémentation efficace d’une heuristique pour inférer ce type de modèle. Utilisez cette librairie pour inférer un modèle MR-Sort à partir du dataset “supermarket”.

Une des difficultés de ce contexte est que les clients n’ont pas tous le même comportement d’achat. Les responsables font l’hypothèse que la clientèle est composée de deux segments. Ainsi, on cherche donc à apprendre un modèle MR-Sort par segment. Dans ce nouveau problème (inv-2-MR-Sort), on cherchera à utiliser l’heuristique de la bibliothèque LINC.S. La difficulté vient du fait qu’il faut, en même temps, partitionner le learning set et apprendre les deux modèles MR-Sort. Proposez une heuristique pour résoudre ce problème.

Votre Jalon 2 doit être déposé sur Edunao au plus tard le 20/10/2026, 23:59.

Jalon 3 (optionnel) et préparation de la soutenance

On s'intéresse à une situation où un utilisateur A cherche à transmettre des données à un utilisateur B, mais cette communication cherche à être brouillée par une tierce personne, comme schématisé ci-dessous. L'utilisateur A collecte des données mais n'a que très peu de puissance de calcul ; il ne fait que transmettre les données qu'il observe à l'utilisateur B. Ces données correspondent à un learning set permettant d'apprendre un modèle de classification MR-Sort (des vecteurs correspondant à la description d'objets et leur classe d'affectation). L'utilisateur B (qui lui dispose de ressources de calcul) reçoit les données et cherche à inférer le modèle MR-Sort correspondant aux données qu'il reçoit. Une tierce personne cherche à brouiller les communications entre A et B, et a la possibilité de transmettre des fausses informations à B (sous la forme de vecteurs correspondant à la description d'objets et leur classe d'affectation). Ainsi, B reçoit un learning set dans lequel certaines des données ont été envoyées par A, et d'autres ajoutées (à des fins de brouillage) par un agent malicieux.



On peut voir cette situation comme un jeu où l'agent malicieux cherche à duper B dans sa tâche d'apprentissage à partir des données qu'il reçoit, et où l'agent B cherche à distinguer les “vraies” données du brouillage introduit par l'agent malicieux pour apprendre correctement le modèle issues des données transmises par l'agent A. On supposera que pour chaque donnée envoyée par A, l'agent malicieux peut envoyer à B une donnée additionnelle.

Dans un premier temps, on considère un agent malicieux “basique” qui envoie des données correspondant à un modèle MR-Sort donné qu'il choisit au hasard. Vous devez utiliser votre travail du Jalon 2 pour aider B à apprendre correctement le modèle MR-Sort correspondant aux données envoyées par A. Implémentez un exemple de ce type de communication avec des données que vous construirez.

Dans un second temps, on vous demande d'aider l'agent malicieux à concevoir une stratégie de brouillage efficace. Pouvez-vous trouver une bonne stratégie de brouillage et montrer sur une instance dans quelle mesure elle entrave l'utilisateur B.

Votre Jalon 3 doit être déposé sur Edunao au plus tard le 05/11/2026, 23:59. Les soutenances ont lieu le 06/11/2026